华中科技大学

课程实验报告

课程名称： 强化学习

基于 DQN 的 Breakout 智能体设计与实现

专业班级	**待填写**
学　　号	**待填写**
姓　　名	**待填写**
指导教师	**待填写**
报告日期	**2026 年 10 月 16 日**

计算机科学与技术学院

目 录

1 DQN 算法原理 **1**
1.1 强化学习任务与长期回报 1
1.2 Q-learning 与神经网络近似 1
1.3 经验回放与目标网络 2
1.4 探索机制与多步回报 2

2 游戏环境建模 **3**
2.1 游戏规则与物理过程 3
2.2 状态、动作与奖励定义 3
2.3 图像预处理与时序信息 4
2.4 回合终止、时间截断与环境一致性 5

3 模型实现 **5**
3.1 整体程序结构 5
3.2 卷积价值网络 6
3.3 训练循环与模型更新 6
3.4 续训、状态保存与实时推理 7

4 训练过程 **7**
4.1 基础训练设置 7
4.2 低学习率续训与策略保护 8
4.3 后续恢复实验与评估协议 8

5 实验结果与分析 **9**
5.1 评价指标与结果来源 9
5.2 各训练阶段的结果 9
5.3 相同开发种子下的候选模型复测 10
5.4 训练回退与恢复实验分析 10
5.5 实时运行与行为分析 11
5.6 实验结论的范围与后续验证 11
5.7 项目工作总结 12

参考文献 **12**

基于 DQN 的 Breakout 智能体设计与实现

1 DQN 算法原理

1.1 强化学习任务与长期回报

Breakout 的控制目标是移动挡板接住小球，并通过小球反弹击碎砖块以获得分数。挡板移动通常不会立即产生奖励，一次接球的收益可能在若干次飞行和碰撞后才体现。因此，智能体需要评价动作对后续游戏过程的影响，而不能只依据当前时刻是否得分决定动作。

设 s_t 为时刻 t 提供给智能体的状态表示，a_t 为动作，r_t 为执行该动作后获得的奖励，T 为本局结束时刻。折扣累计回报定义为

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k}, \qquad J(\pi) = \mathbb{E}_\pi[G_0], \tag{1.1}$$

其中 π 为策略，$\gamma \in [0, 1)$ 为折扣因子。本项目取 $\gamma = 0.99$，使价值估计兼顾近期击砖奖励与未来继续得分的机会。训练目标是提高期望折扣回报；实验评估则报告整局未折扣的游戏总分，两者含义不同。

动作价值函数描述在状态 s 下先执行动作 a，随后按策略 π 行动时的预期回报：

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a]. \tag{1.2}$$

在同一画面下，向左或向右移动可能带来不同的后续接球机会。价值函数将这种长期差异转化为可比较的数值。若最优动作价值函数 Q^* 已知，就可以采用 $\arg\max_a Q^*(s, a)$ 选择动作。

1.2 Q-learning 与神经网络近似

最优动作价值满足 Bellman 最优关系，即当前动作的价值由即时奖励和下一状态的最优未来价值共同决定：

$$Q^*(s, a) = \mathbb{E}\Big[r + \gamma(1 - d) \max_{a'} Q^*(s', a') \mid s, a\Big], \tag{1.3}$$

其中 s' 是下一状态，d 表示真正终止。表格型 Q-learning 利用一次环境转移更新对应表项：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \Big[r_t + \gamma(1 - d_t) \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)\Big]. \tag{1.4}$$

这里 α 为学习率，方括号中的差值是时间差分误差。更新通过下一状态的估计值修正当前价值，因此不必等一局游戏全部结束后才开始学习。

图像状态的组合数量远大于表格能够存储的范围。DQN 用参数为 θ 的神经网络 $Q_\theta(s,a)$ 近似动作价值，并通过共享视觉特征将已见画面的经验迁移到相似画面。经典 DQN 将卷积表示与价值学习结合，建立了从像素输入到离散动作决策的学习框架 [1]。本项目沿用该框架，网络输出四个动作的 Q 值，而不是直接输出动作概率。

1.3 经验回放与目标网络

神经网络训练通常希望样本具有较低的相关性，而游戏中相邻画面非常相似。若严格按采样顺序立即更新，参数容易受近期轨迹支配。经验回放池 $\mathcal{D}$ 保存转移

$$e_t = (s_t, a_t, r_t, s_{t+1}, d_t), \tag{1.5}$$

训练时从池中随机抽取小批量样本。这样既减弱相邻转移之间的相关性，也允许同一条有效经验被多次利用。低奖励和失球经验同样保留在池中，因为区分成功与失败对动作评价都具有意义。

DQN 同时维护在线网络 Q_θ 与目标网络 Q_{θ^-}。在线网络参与梯度更新并用于决策；目标网络在一段时间内保持不变，用于构造学习目标，随后从在线网络复制参数。一步 TD 目标和误差写为

$$y_t = r_t + \gamma(1-d_t)\max_{a'} Q_{\theta^-}(s_{t+1}, a'), \tag{1.6}$$

$$\delta_t = y_t - Q_\theta(s_t, a_t). \tag{1.7}$$

目标网络将监督目标的变化与每次在线更新适度分离，缓解自举估计与参数更新相互追逐的问题。计算 y_t 时停止梯度传播，梯度仅作用于在线网络。

本项目使用 Stable-Baselines3 的 DQN 实现 [2]，采用 Huber 损失：

$$\ell(\delta) = \begin{cases} \frac{1}{2}\delta^2, & |\delta| \le 1, \\ |\delta| - \frac{1}{2}, & |\delta| > 1, \end{cases} \qquad \mathcal{L}(\theta) = \frac{1}{B}\sum_{i=1}^{B} \ell(\delta_i). \tag{1.8}$$

其中 B 为批大小。小误差区域使用平方形式，大误差区域使用线性形式，从而减弱个别较大 TD 误差对更新的影响。优化器采用 Adam。损失减小表示网络更接近当前样本上的 TD 目标，并不直接意味着下一次评估的游戏得分必然提高。

1.4 探索机制与多步回报

训练采用 ε-greedy 策略：

$$a_t = \begin{cases} \text{从动作空间均匀采样}, & \text{概率为}\varepsilon_t, \\ \arg\max_a Q_\theta(s_t, a), & \text{概率为}1-\varepsilon_t. \end{cases} \tag{1.9}$$

早期较大的 ε_t 帮助收集不同状态与动作的经验，后期降低探索率以更多利用已学策略。开发评估采用贪心动作，因此训练阶段含随机探索的回合分数与评估分数应分别解释。

对于延迟奖励，一步目标需要通过多次自举将价值向前传播。项目还尝试了三步回报。中间没有真正终止时，其目标为

$$y_t^{(3)} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 \max_{a'} Q_{\theta^-}(s_{t+3}, a'). \tag{1.10}$$

若提前终止，则仅累积终止前的奖励，并去除终止后的自举项。多步回报可以更直接地利用后续实际奖励，但也引入更长轨迹中的随机性和行为策略影响，其效果需要结合实验判断。本项目主要结果采用一步 DQN，三步设置作为后续恢复实验。

2 游戏环境建模

2.1 游戏规则与物理过程

项目在 Gymnasium 接口下实现固定球速 Breakout 环境。画面分辨率为 210×160，包含小球、挡板、砖块、边界以及分数和剩余生命显示。每局有 5 条生命，每面砖墙有 $6 \times 18 = 108$ 块砖，共设置两面砖墙。各行砖块从上至下分别计 7、7、4、4、1、1 分，因此一面墙为 432 分，整局最高分为 864 分。

物理系统以 60 Hz 更新，小球每帧移动 2 像素，即球速固定为 120 像素/秒。挡板宽度固定为 16 像素，单个物理帧向左或向右移动 3 像素。碰撞后小球改变运动方向但保持速度模长。将球速和挡板宽度固定，可以减少随游戏进程变化的额外难度因素，使模型在一致的控制条件下学习。

小球与挡板接触的位置决定反弹方向。挡板横向划分为五个区域，越靠近边缘，反弹方向越偏向相应侧；中心区域保留小角度水平分量，避免长时间完全垂直往返。该规则不随累计接球次数改变。砖块碰撞使用运动路径与扩展矩形的相交检测，在一个物理步内寻找最早接触点，处理反射并继续推进剩余时间，以避免仅检查离散终点造成漏碰撞。

发球位置和初始水平方向由随机种子控制。第一面砖墙清空后重建第二面墙并重新发球；生命耗尽或第二面砖墙清空时游戏真正结束。该环境是按任务需要重建的游戏，其几何和反弹规则由项目代码定义，实验分数对应这一固定规则环境。

2.2 状态、动作与奖励定义

物理环境的完整状态可以表示为小球位置与速度、挡板位置、砖块存活标记、剩余生命、当前墙面以及发球状态等变量的集合。这些变量决定下一步物理变化。智能体实际获得的是渲染图像，模型不直接读取球坐标、速度或预先计算的落点。

游戏实时展示画面

放置网页运行截图，保留模型名称、分数、剩余生命及完整游戏区域。

待插入文件：`images/game_live.png`

图 1　Breakout 实时运行界面（图片待补充）。

动作空间为四个离散动作，如表1所示。自动发球包装器在等待发球时将当前动作替换为发球动作，并在正常的物理步中执行，不额外插入隐藏帧。因此，学习任务主要集中在接球与击砖控制。

表 1　环境动作空间与控制含义

动作编号	动作名称	物理控制含义
0	NOOP	挡板保持当前位置
1	FIRE	等待发球时发射小球
2	RIGHT	挡板向右移动，受右边界约束
3	LEFT	挡板向左移动，受左边界约束

奖励直接采用当前动作执行期间击碎砖块获得的原生分数：

$$r_t = \sum_{b \in \mathcal{B}_t} v(b), \tag{2.1}$$

其中 $\mathcal{B}_t$ 为该决策步内被击碎的砖块集合，$v(b)$ 为砖块所在行对应的分值。项目不额外设置接球奖励、存活奖励或失球惩罚，也不进行奖励裁剪。这样，策略的优化信号与击砖得分保持一致。失球虽然没有直接的负奖励，但会减少剩余生命和未来得分机会，其影响可以通过长期价值反映出来。

2.3　图像预处理与时序信息

单张画面可以反映小球的位置，却无法可靠区分运动方向。项目将连续四张处理后的画面堆叠，作为对运动状态的近似表示。共享环境工厂按以下顺序处理图像。

首先，将一个动作重复执行 4 个物理帧，并累加期间的奖励。随后，对实际产生的最后两帧逐像素取最大值，得到池化画面。若提前终止或截断，则使用真正发生的末尾画面，避免把旧帧当成终止观测。之后，使用灰度转换和缩放得到 84×84 图像，再按时间顺序堆叠 4 帧，并将通道维移动到最前端。

因此，单个状态表示为

$$s_t = [o_{t-3}, o_{t-2}, o_{t-1}, o_t] \in \{0, \ldots, 255\}^{4\times84\times84}. \tag{2.2}$$

单环境批输入的形状为 $(1, 4, 84, 84)$，原始存储类型为 `uint8`。网络内部将像素转换为浮点数并除以 255。堆帧允许卷积网络利用位置变化判断运动趋势，但它仍是从图像得到的近似状态表示。

图像预处理示意

依次展示原始 RGB 画面、最大池化与灰度缩放结果、四帧堆叠输入；标注各阶段尺寸。

待插入文件：`images/observation_pipeline.png`

图 2　从游戏画面到 DQN 输入的预处理流程（图片待补充）。

2.4 回合终止、时间截断与环境一致性

项目以一整局游戏作为一个回合，损失一条生命不会立即终止回合。只要仍有剩余生命，环境就准备并自动发射下一球。这样可以让价值估计覆盖一局中的多次失球和后续得分机会。

单局上限设置为 108000 个物理帧。达到上限属于时间截断，生命耗尽或通关属于真正终止，两者在学习目标中需要区分。真正终止时未来价值为零；时间截断则仍需要基于截断时的最终观测进行适当自举。环境包装器保留相应标记和终止观测，由训练库的回放与目标计算流程处理。

训练、独立评估、实时展示和视频录制共用同一套环境与预处理代码。模型保存环境版本和关键参数，加载时检查球速、挡板宽度、图像尺寸、堆帧数量和奖励规则等设置。该检查能够阻止外形相同但物理规则不同的历史模型被误用于当前任务。

3 模型实现

3.1 整体程序结构

系统以 Python 为主要开发语言，使用 Gymnasium 封装环境，使用 Stable-Baselines3 调用 DQN 学习流程，并通过网页展示模型运行过程。项目的主要实现工作包括游戏物理与渲染、预处理封装、训练参数管理、模型恢复、评估回调和实时推理接口。DQN 的卷积特征提取、TD 目标、回放采样和梯度更新由训练库完成。

环境层接收离散动作，推进物理过程并返回图像、奖励和结束标记；学习层将图像送入 Q 网络，依据探索策略选择动作，再把交互结果存入回放池；管理层定期评

估当前模型并保存检查点；展示层加载已保存模型，用相同观测接口执行贪心控制。各层共享任务定义，而训练和评估使用独立的环境实例。

表 2　核心程序模块及其职责

模块	主要实现内容
`fixed_breakout.py`	游戏物理、碰撞、计分、渲染、自动发球与动作重复
`env.py`	环境工厂、版本检查、灰度缩放、帧堆叠与通道转换
`train.py`	参数解析、初始化与续训、日志记录、模型保存
`warm_start_dqn.py`	续训预热阶段沿用已有策略采样
`callbacks.py`	开发评估、最佳模型选择、早停与训练状态记录
`replay_io.py`	回放池保存、压缩、恢复与兼容性检查
`evaluate.py`	逐局种子评估、结果导出及随机策略比较入口
`dashboard.py`、`game_viewer.py`	网页展示、模型切换、暂停及播放控制

3.2　卷积价值网络

模型采用 `CnnPolicy`，使用 NatureCNN 风格的卷积特征提取器。输入的四帧图像沿通道维拼接，卷积同时提取空间结构与跨帧差异。三层卷积之后将特征展平，经过 512 维全连接层，再由动作价值输出层产生四个 Q 值。各层使用的尺寸列于表3。

表 3　DQN 卷积价值网络结构，省略批维度

层	运算与参数	输出尺寸
输入	四帧灰度图像；像素除以 255	$4 \times 84 \times 84$
卷积 1	32 个 8×8 卷积核，步长 4，ReLU	$32 \times 20 \times 20$
卷积 2	64 个 4×4 卷积核，步长 2，ReLU	$64 \times 9 \times 9$
卷积 3	64 个 3×3 卷积核，步长 1，ReLU	$64 \times 7 \times 7$
展平	按通道和空间位置展开	3136
全连接	$3136 \to 512$，ReLU	512
输出层	$512 \to 4$，线性输出	4

输出层不使用 softmax，因为 Q 值表示预期回报，可以是任意实数。动作选择依据输出值的相对大小进行。在线网络与目标网络具有相同结构，目标网络由在线网络周期性复制得到。当前实现使用普通 DQN 的最大目标值计算，没有加入 Double DQN、Dueling 结构或优先经验回放。

网络不显式预测小球落点，也不包含人工编写的追球控制规则。像素特征是否有利于接球，需要通过环境交互产生的奖励逐步学习。由此，模型实现将视觉表示与控制目标连接起来，而游戏的物理状态仅用于环境内部更新和调试。

3.3　训练循环与模型更新

训练流程可归纳为如下过程，其中环境步均指经过动作重复包装后的决策步：

1. 初始化在线网络，复制其参数得到目标网络，建立回放池并重置环境。
2. 根据当前探索率选择动作，执行环境步，获得新观测、累计奖励和结束信息。
3. 将转移存入回放池；回合结束后重置环境，继续收集完整游戏经验。
4. 超过预热步数后，每收集 4 个决策步执行 1 次梯度更新，每次随机采样 32 条转移。
5. 使用目标网络构造 TD 目标，以 Huber 损失更新在线网络；每 10000 个决策步同步目标网络。
6. 定期运行独立开发评估，保存检查点和表现最好的模型，达到预算或早停条件后结束。

这里动作重复 4 帧与每 4 个决策步训练一次是两个不同层次的设置。前者控制智能体多久重新作出一次决策，后者控制采样与参数更新的比例。在未提前结束的情况下，一次梯度更新通常对应最近约 16 个物理帧的采样。报告中的 50 万步等训练预算均采用决策步计数。

3.4 续训、状态保存与实时推理

模型文件保存网络参数、优化器状态及相关配置，但不自动包含经验回放池。项目因此把回放池作为独立产物保存，并检查其环境定义、容量与回报跨度是否与待恢复模型兼容。压缩用于降低磁盘占用，训练时解压后的回放仍需要相应内存。

在缺少配套回放池的续训中，模型从已有权重开始建立新的回放池。项目实现了策略预热：前 20000 个决策步仍暂缓梯度更新，但动作由恢复后的 ε-greedy 策略产生。这样，预热数据与当前策略的访问状态更接近，而不是重新由完全随机动作填充。这种操作属于基于已有模型的新阶段训练，不等同于完整恢复原训练过程。

实时展示加载候选模型并采用贪心动作。网页提供模型选择、随机策略、暂停、倍速和全屏等控制，显示实际物理帧；1 倍播放以 60 个物理帧/秒为目标。展示用于观察接球、移动和击砖轨迹，定量评价仍依赖多局评估的统计结果。

4 训练过程

4.1 基础训练设置

基础实验使用训练种子 42，从随机初始化开始训练 500000 个决策步。初始探索率为 1.0，在前 60% 的训练预算内线性下降至 0.05，之后保持不变。学习率固定为 10^{-4}，回放容量为 50000，预热步数为 20000。主要参数与续训参数的对照见表4。

50000 条图像转移需要较大的内存。若分别以 `uint8` 保存当前与下一堆帧观测，仅这两部分约占 $2 \times 50000 \times 4 \times 84 \times 84 = 2.8224 \times 10^9$ 字节，约为 2.82 GB，其他字段和运行过程还会带来额外开销。因此，回放容量同时影响可保留的历史范围与内存需求。

表 4　从头训练与当前低学习率续训配置

参数	从头训练	低学习率续训
阶段预算（决策步）	500000	200000
学习率	1×10^{-4}	$3 \times 10^{-5} \rightarrow 1 \times 10^{-5}$
折扣因子 γ	0.99	0.99
回放池容量	50000	50000
新回放池预热步数	20000	20000
批大小	32	32
训练频率 / 每次梯度步数	4 / 1	4 / 1
目标网络同步间隔	10000	10000
探索率变化	$1.00 \rightarrow 0.05$	$0.05 \rightarrow 0.02$
探索率衰减占阶段比例	60%	100%
回报跨度	1 步	1 步
评估间隔（决策步）	50000	25000
每次评估局数	20	50

训练过程记录回合奖励、回合长度、探索率、损失、回放池大小和梯度更新次数等信息，并定期保存模型检查点。基础实验每 50000 步进行一次 20 局开发评估，使用评估均分选取最佳模型。

4.2　低学习率续训与策略保护

基础模型获得一定控制能力后，项目开展低学习率续训，尝试在已有策略附近继续改进。续训阶段预算为 200000 步，学习率从 3×10^{-5} 线性下降到 10^{-5}，探索率从 0.05 下降到 0.02，每 25000 步评估 50 局。减小学习率有助于缩小单次参数变化幅度，但能否维持已有能力仍取决于新经验分布和价值估计。

现有记录显示，低学习率续训在阶段 25000 步取得最佳开发均分，此后继续训练并未保持这一水平。针对该现象，当前续训配置加入起点评估、策略预热和连续 3 次开发评估未改进时早停等保护。起点评估先把恢复的模型纳入候选，避免一次较弱的新检查点被当成该阶段的最佳模型；预热期间尚未更新参数，重复评估不会消耗早停耐心；产生新最佳结果时同步保存模型和对应回放池。

上述保护是工程整理后的当前配置。历史低学习率实验完整运行至 200000 步，其结果不能被解释为当前早停配置下重新运行的结果。配置用于说明可复现的训练入口，历史表现则按项目已有记录报告。

4.3　后续恢复实验与评估协议

在低学习率续训之后，项目又尝试了三步回报恢复和一步扩大回放池两种设置。前者希望加快延迟奖励的利用，后者希望延长历史经验的保留时间。两次实验均未超过恢复起点的开发均分，并在 50000 步时早停。现有汇总记录没有包含扩大回放实验的完整容量数值，因此本报告仅描述已记录的实验方向与结果。

开发评估在独立环境中进行，使用贪心策略，且不更新参数。训练回调以种子 31000 初始化后生成连续游戏序列，模型选择所用数据属于开发数据。基础训练每次评估 20 局，续训与恢复实验每次评估 50 局，样本规模不同。

独立复测采用另一种逐局设种方式：第 i 局显式重置为对应种子，使不同候选模型面对相同的开局种子集合。现有记录包含 42000 至 42029 共 30 个开发种子的复测结果。它与训练回调的连续游戏序列是两套不同协议，各自的均分分别报告，不混合计算。

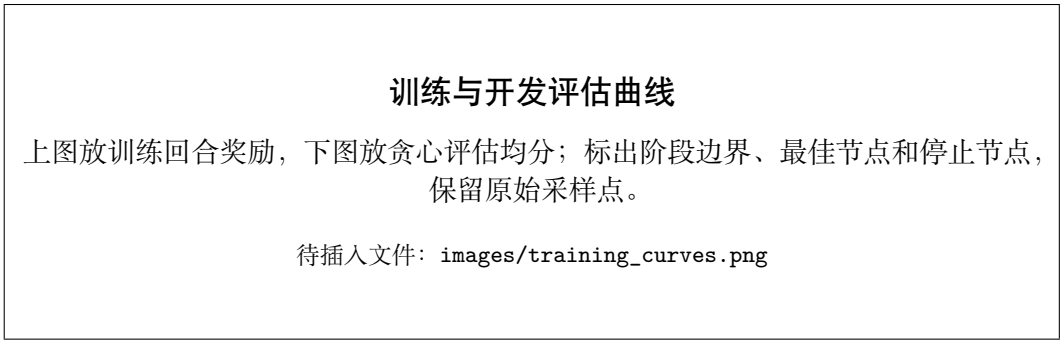


图 3　训练进程与开发评估得分变化（曲线待由训练日志补充）。

5　实验结果与分析

5.1　评价指标与结果来源

每局游戏总分定义为 $R_i = \sum_{t=0}^{T_i-1} r_t$。对 N 局游戏，平均分与总体形式的标准差分别为

$$\overline{R} = \frac{1}{N}\sum_{i=1}^{N} R_i, \qquad \sigma_R = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(R_i - \overline{R})^2}. \tag{5.1}$$

平均分衡量总体得分水平，中位数反映典型游戏表现，标准差和低分位数用于分析波动。仅报告最高分容易放大少数成功轨迹的影响；仅报告损失则不能直接反映控制效果。

本节数值来自项目已有的实验汇总记录。该记录给出了各阶段最佳均分、结束均分和补充复测的部分统计量，没有提供本地可直接绘图的完整逐局数据。已有数值保留在结果表中，训练曲线、得分分布和行为截图的位置使用占位框，待相应日志与截图补入。

5.2　各训练阶段的结果

表5给出当前物理版本下的实验结果。表中最佳节点指该阶段开发评估均分最高的节点；后两个恢复实验的最佳模型均为恢复起点，而非新训练得到的模型。

基础训练在 350000 步时取得 174.00 的最佳均分，结束时下降到 133.30，减少 40.70 分。低学习率续训的最佳均分为 283.48，出现在阶段 25000 步；结束时为 113.12，

表 5　各阶段开发评估结果

实验阶段	最佳节点	最佳均分	结束均分	局数
从头训练 500k	350k	174.00	133.30	20
一步低学习率续训 200k	本阶段 25k	283.48	113.12	50
三步回报恢复	起点；50k 早停	283.48	187.78	50
一步扩大回放	起点；50k 早停	283.48	216.94	50

注：1k = 1000 个决策步；“局数”为每次评估局数。不同阶段的评估规模不同，表中数值用于呈现各阶段轨迹与模型选择结果。

比最佳节点低 170.36 分。两组结果共同说明，增加训练步数并不保证策略持续改善，最终模型与最佳模型需要分别保存。

基础阶段和续训阶段的最高均分来自不同局数的评估，并且续训同时改变了模型起点、训练预算、学习率与探索安排。因此，不能把二者的差值直接归因于降低学习率。更有信息量的比较来自同一协议下的候选模型复测。

5.3　相同开发种子下的候选模型复测

在 42000 至 42029 的相同 30 个开发种子上，当前推荐的最佳模型取得平均分 260.27、中位数 257.00；上一轮最终模型的平均分为 122.40，如表6所示。

表 6　相同 30 个开发种子上的独立复测

候选模型	平均分	中位数	局数
当前推荐最佳模型	260.27	257.00	30
上一轮最终模型	122.40	未记录	30

两者平均分相差 137.87 分，相对增加约 112.64%。由于这次比较使用相同种子集合，它支持在所测开局条件下选择当前推荐模型。最佳模型的均值与中位数接近，说明其中位水平也达到约 257 分；不过，仅凭这两个统计量仍无法确定低分局比例或尾部分布，还需要逐局数据进一步分析。

这里的“上一轮最终模型”沿用实验汇总中的候选名称，现有记录未给出其完整文件身份。因而该比较用于说明已有候选复核结果，不额外推断其对应哪一轮训练终点。当前推荐模型的项目路径为

```
models/dqn_custom_fixed_angle_refine_200k/best_model/best_model.zip
```

5.4　训练回退与恢复实验分析

训练后期的回退首先反映出模型参数更新与策略性能之间并非单调关系。DQN 的学习目标包含目标网络估计，回放池又不断接收新策略产生的数据。即使当前小批量上的损失降低，也可能改变关键状态下的动作排序，进而影响之后整条轨迹。一次错误移动造成失球，还会减少后续继续获得奖励的机会。

相同种子下的得分分布

根据 30 局原始记录绘制逐种子配对散点图或箱线图；标出均值和中位数，不用汇总均值反推逐局数据。

待插入文件：images/score_distribution.png

图 4　候选模型在相同开发种子下的得分分布（图片待补充）。

回放分布变化是可能的解释之一。当回放容量有限时，较早阶段的有效经验会逐步被新经验替换；若新策略访问的状态变窄，网络可能减少对某些关键接球状态的训练。另一方面，自举估计误差、探索变化和不同开局下的轨迹差异也可能影响结果。现有汇总统计不能单独识别这些因素的贡献，因而回退原因仍属于需要通过日志和控制实验检验的解释。

三步回报恢复结束均分为 187.78，一步扩大回放结束均分为 216.94，均低于起点的 283.48。这说明在已执行设置下，两种恢复方案都没有形成超过起点的新最佳策略。三步目标引入更多真实奖励，并不保证在当前数据分布上优于一步目标；扩大回放也会同时改变经验新旧比例，不能简单等同于增强稳定性。

早停和最佳模型保存的作用是保留已有成果并减少继续退化阶段的计算支出。它们改变的是训练管理和模型选择方式，并没有使每一步更新都具备性能保证。当前选择依据应是独立评估结果，而不是模型文件的生成时间或累计训练步数。

5.5　实时运行与行为分析

实时游戏画面适合补充统计分数背后的行为解释。对同一局游戏，应按时间顺序记录小球下降、挡板移动、接触瞬间和反弹后的连续画面，同时保留模型、种子、分数及生命信息。仅有单帧画面难以判断运动方向，也不能说明一次接球是主动预测还是偶然重合。

行为分析重点关注挡板与小球的相对运动：挡板是否在球下降阶段提前向落点移动，接近边界时是否仍有有效控制空间，以及反弹后能否及时调整方向。图5预留成功接球与失球过程的连续截图，用于对照相似局面下的动作差异。具体轨迹结论需在补入对应截图后给出；单凭平均分不能判断模型是否学会了精确落点预测或特定击砖策略。

5.6　实验结论的范围与后续验证

现有实验以开发评估和候选模型选择为主。代码提供随机策略比较入口，但当前材料没有可用于本报告的随机基线统计；最终留出种子上的测试也尚未完成。因此，现有结果支持比较已记录候选模型在开发条件下的表现，还不能量化相对随机策略的提升，也不能据此声称稳定通关或跨环境泛化。

模型行为连续帧

上排放成功接球的连续 3 至 4 帧，下排放失球案例；使用同一模型并标注种子、时间顺序及分数。

待插入文件：`images/behavior_sequence.png`

图 5　接球与失球过程的定性对照（截图待补充）。

后续验证应在模型选定后固定权重，用未参与选择的种子进行完整游戏评估，并让随机策略使用相同任务与种子集合。除了平均分，还应报告标准差、中位数、低分位数、低分局比例、通关率和时间截断比例。若要评价训练方法的可重复性，还需要多个独立训练种子；对同一个模型增加开局种子只能反映该模型在不同游戏初始条件下的波动。

对于学习率、回报跨度和回放容量的作用，可以从同一模型起点出发，固定其余设置并分别改变一个因素。这样能够进一步区分模型起点、额外交互预算和参数设置对结果的影响。当前恢复实验的负结果应保留为已有观察，而不是在缺少新数据时替换为预期提升。

5.7　项目工作总结

本项目把 Breakout 控制任务转化为可交互的强化学习环境，定义了离散动作、原生击砖奖励和完整回合终止规则，并通过统一图像处理接口连接训练、评估与实时展示。模型以连续像素画面为输入，借助卷积网络、经验回放和目标网络完成价值学习；工程实现补充了训练日志、检查点、回放恢复、起点评估和早停保护，使实验过程能够被记录和复核。

实验中的主要认识是，策略水平需要由多局评估与候选模型复测共同判断。低学习率续训产生了表现较好的中间模型，但继续训练发生回退；随后两项恢复实验也没有超过原有起点。保留最佳模型、区分训练阶段与评估协议、记录失败或未改进的实验，与提升单次最高得分同样影响项目结论的可靠性。通过这一过程，项目完成了从 DQN 理论到图像控制系统的实现，并明确了进一步验证策略稳定性所需的实验条件。

参考文献

[1] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518: 529–533. https://doi.org/10.1038/nature14236.

[2] Stable-Baselines3 Contributors. DQN: algorithm and implementation documentation[EB/OL]. https://stable-baselines3.readthedocs.io/en/master/modules/dqn.html.

[3] 本项目源代码与实验记录：项目说明、强化学习技术报告、修改汇总与训练结果、训练配置，以及 src/ 目录下的实现代码。